

DataStory AI

Аналитик получает таблицу и должен вручную превратить её в ответ



Долгая ручная настройка

Показатель, группировка, график и вывод — каждый раз руками



Свои названия показателей

«cancellation rate», «средний чек» — у каждой компании термины разные



Модель может выдумать

Таблица «как есть» отдана модели — риск придуманного числа или причины

Один экран, три шага

1 · Загрузка

XLSX, CSV или фото

Плюс вопрос обычным языком:
«покажи динамику выручки...»



2 · План (пауза)

**LLM предлагает, вы
подтверждаете**

Настоящий interrupt LangGraph —
расчёты не начнутся без вас



3 · Дашборд

**MCP считает, RAG
подтверждает термины**


Вывод проходит проверку: числа,
причины, рост/снижение

«Покажи динамику выручки по месяцам, сравни регионы и найди основные изменения»

План: 2 шага, план построен за 6,8 с

Динамика выручки (Month × Region) — линейный ·
Сравнение регионов — столбчатый. Определение Revenue
найдено в sales_metrics.pdf

Выручка по регионам



Рост Алматы

+17,37 млн ₸ · +22,0%

Общий рост янв→июн

+44,74 млн ₸ · +21,5%

Найдено при аудите, не в выводе

Astana март→апрель −36,4%

«Покажи cancellation rate по месяцам»

Месяц	2026-01	2026-03	2026-06
Cancellation rate	4,41%	4,51% · максимум	4,33%

о
С
а
н
с
е

ч
В
с

Б
е
-
К
а
р
т
о
ч
к

Мультимодальность: таблица прочитана с фотографии

gpt-4o-mini Vision → 6 строк × 3 колонки

Пользователь правит ячейки и подтверждает — дальше тот же путь, что у XLSX

Точность распознавания


18 / 18 значений · 9 из 9 прогонов

Честно: план по расплывчатому запросу нестабилен


«Динамика показателя по месяцам» на этой картинке (два показателя в таблице) — план построился в 2 из 7 прогонов

Month	Orders	Revenue_KZT
2026-01	9 798	208 316 536
2026-02	9 981	213 360 205
2026-03	10 225	223 975 319
2026-04	10 401	205 544 195
2026-05	10 659	241 591 934
2026-06	11 051	253 055 653

Компоненты и граф LangGraph



9 узлов, 5 условных переходов — упрощённый путь одного анализа:



Один запрос: от вопроса до ответа

1. Файл или фото → профиль → рабочее хранилище
2. RAG ищет фрагменты документов по запросу (Top-k)
3. LLM предлагает план — строго по Pydantic-схеме
4. Код проверяет план по данным: показатель, колонки, фильтры
5. Пауза — human_approval, ждём пользователя
6. MCP считает calculate_metrics по каждому шагу
7. LLM пишет вывод по уже готовым числам
8. Код проверяет вывод: числа, причины, рост/снижение
9. Дашборд, Markdown-отчёт, чат по результату

Почему MCP, а не обычный вызов функции?

Инструмент изолирован от UI, интерфейс «tool» настоящий, тот же клиент переиспользует и чат

LLM

gpt-4o-mini · temperature 0 · max_tokens 1024 · ≈ \$0,001 за вызов плана (измерено)

Fallback LLM

Нет ключа / ошибка / лимит токенов
→ детерминированные правила, а не другая модель

30 golden cases, автоматический прогон

Группа (5 случаев каждая)	Пример запроса
1. Интерпретация показателя	«Какой средний чек по каналам?»
2. Динамика во времени	«Покажи динамику выручки по месяцам»
3. Сравнение категорий	«Сравни регионы по выручке»
4. Фильтры	«Сравни выручку Web и Mobile»
5. Термины из базы знаний	«Покажи cancellation rate»
6. Недопустимые / неоднозначные	«Покажи EBITDA»

Retrieval Hit@3	100% · 26/26
Numeric Accuracy	100% · 25/25
Invalid rejection	100% · 4/4
Plan Accuracy	96% · 24/25

До фикса планировщика колебалось 96→100→80% между прогонами; единственный промах теперь — «прибыль» не отклоняется (iv-03)

А/В по RAG и подбор temperature

А/В: RAG в промпте планировщика

30 случаев × 3 повтора · А — без RAG, В — Top-5 RAG

Метрика	А	В	Вывод
Plan Accuracy	89,3%	90,7%	не подтверждено
RAG-dependent	80,0%	80,0%	разницы нет
Retrieval Hit@3 (В)	—	100%	78/78

«RAG лучше» — не подтверждено

Гиперпараметры: temperature

10 случаев × 5 повторов · T0 против T0,4

Метрика	T0	T0,4	Вывод
Plan Accuracy	80,0%	87,5%	не различимо
Стабильность структуры	94%	86%	не подтверждено
Токены LLM / запрос	7 484	6 643	0,4 дешевле

Выбрано: temperature 0, max_tokens 1024

Сквозной путь работает: файл или фото → план с подтверждением → расчёты → проверенные выводы

✓ Числа: 100% совпадение с pandas — 25/25 golden cases и оба живых сценария

✓ LangSmith: трейсы подтверждены в облаке, не только в тестах

✓ RAG: определения показателей — с источником, страницей и разделом

